

SLAM 問題の定式化

にゃーん

2019 年 10 月 31 日

1 SLAM 問題の分類

SLAM(スラム) は Simultaneous Localization And Mapping の略称であり、自己位置推定と地図構築を同時に行う問題である。移動ロボットが、周囲の環境の地図を持たず、また自己の姿勢も分からないという状況にあるとき、環境の地図を構築しながら、その地図上での自己位置を推定しなければならない。しかし、ロボットが計測データを使って地図を生成するためには、ロボットの自己位置が必要であり、またロボットの自己位置を推定するためには地図が必要である。即ち、自己位置推定と地図構築は相互依存の関係にあるため、SLAM の問題を解くのは一層困難になる。

1.1 オンライン SLAM 問題

SLAM 問題は、オンライン **SLAM** 問題 (Online SLAM) と完全 **SLAM** 問題 (Full SLAM) の 2 種類に分けられる [1][2]。オンライン SLAM 問題では、時刻 t における姿勢 x_t 地図 m の事後確率 $p(x_t, m | z_{1:t}, u_{1:t})$ を求める。オンライン SLAM はその名の通り、各時刻において事後確率を求める、逐次的なアルゴリズムである。以下の漸化式を利用すれば、時刻 t における事後確率 $p(x_t, m | z_{1:t}, u_{1:t})$ を、時刻 $t-1$ における事後確率 $p(x_{t-1}, m | z_{1:t-1}, u_{1:t-1})$ から求められる。ベイズフィルタの導出と同様にして、漸化式は次のように得られる。

$$\begin{aligned} & p(x_t, m | z_{1:t}, u_{1:t}) \\ = & \frac{p(z_t | x_t, m, z_{1:t-1}, u_{1:t-1}) p(x_t, m | z_{1:t-1}, u_{1:t-1})}{p(z_t | z_{1:t-1}, u_{1:t-1})} \quad (\because \text{ベイズの定理}) \end{aligned} \quad (1)$$

$$= \eta p(z_t | x_t, m, z_{1:t-1}, u_{1:t-1}) p(x_t, m | z_{1:t-1}, u_{1:t-1}) \quad (2)$$

$$= \eta p(z_t | x_t, m) p(x_t, m | z_{1:t-1}, u_{1:t-1}) \quad (3)$$

ここで $\eta = p(z_t | z_{1:t-1}, u_{1:t-1})$ は、現在の状態 x_t と地図 m には依存しないため、定数項として扱っている。最後の式変形では、現在の計測 z_t は、現在の姿勢 x_t と地図 m によって決まり、それ以外の変数 ($z_{1:t-1}, u_{1:t-1}$) とは独立であることを利用している。右側の項 $p(x_t, m | z_{1:t-1}, u_{1:t-1})$ は次のように、変数 x_{t-1} に関する周辺化として記述される。

$$\begin{aligned} & p(x_t, m | z_{1:t-1}, u_{1:t-1}) \\ = & \int p(x_t, x_{t-1}, m | z_{1:t-1}, u_{1:t-1}) dx_{t-1} \end{aligned} \quad (4)$$

$$= \int p(x_t | x_{t-1}, m, z_{1:t-1}, u_{1:t-1}) p(x_{t-1}, m | z_{1:t-1}, u_{1:t-1}) dx_{t-1} \quad (5)$$

$$= \int p(x_t | x_{t-1}, u_t) p(x_{t-1}, m | z_{1:t-1}, u_{1:t-1}) dx_{t-1} \quad (6)$$

最後の式変形では、マルコフ性の仮定から、現在の状態 x_t は、直前の状態 x_{t-1} と制御 u_t のみに依存し、従ってそれ以外の変数 ($m, z_{1:t-1}, u_{1:t-1}$) とは独立であることを利用している。また時刻 $t-1$ における状態 x_{t-1} は、未来の時刻 t における制御 u_t とは関係ないことも利用している。地図 m が現在の状態 x_t の推定に何らかの有益な情報をもたらす場合、 x_t は m とは独立にはならず、 $p(x_t | x_{t-1}, u_t) \neq p(x_t | x_{t-1}, u_t, m)$ となる。しかし、ここでは x_t が m とは独立と仮定している。このとき漸化式は以下ようになる。

$$p(x_t, m | z_{1:t}, u_{1:t}) = \eta p(z_t | x_t, m) \int p(x_t | x_{t-1}, u_t) p(x_{t-1}, m | z_{1:t-1}, u_{1:t-1}) dx_{t-1} \quad (7)$$

漸化式には、状態遷移確率 $p(x_t|x_{t-1}, u_t)$ と計測確率 $p(z_t|x_t, m)$ の双方が含まれている。最初に制御 u_t を用いて、直前の事後確率 $p(x_{t-1}, m|z_{1:t-1}, u_{1:t-1})$ と状態遷移確率 $p(x_t|x_{t-1}, u_t)$ の積を周辺化し、現在の状態 x_t に関する予測を確率分布 $p(x_t, m|z_{1:t-1}, u_{1:t})$ として得る。次に計測 z_t を用いて、確率分布 $p(x_t, m|z_{1:t-1}, u_{1:t})$ と計測確率 $p(z_t|x_t, m)$ との積を求め、時刻 t における事後確率 $p(x_t, m|z_{1:t}, u_{1:t})$ を得る。即ち事後確率の更新は、予測と修正の 2 ステップに分けられる。制御 u_t を使って状態 x_t に関する予測を立てた後、計測 z_t を使って予測を修正し、かつ現在の地図 m に対する推定を行う。これよりオンライン SLAM 問題は、拡張カルマンフィルタやパーティクルフィルタのような、ベイズフィルタの枠組みで計算できる。

オンライン SLAM 問題は、図 1 に示すような確率モデルとして表現される。図 1 では、現在の状態 x_t は直前の状態 x_{t-1} と制御 u_t にのみ依存することと、計測 z_t は現在の状態 x_t と地図 m にのみ依存することの両方が表現される。状態遷移確率 $p(x_t|x_{t-1}, u_t)$ と計測確率 $p(z_t|x_t, m)$ の形から、変数間の依存関係は明らかである。またオンライン SLAM 問題において推定したい変数は、図 1 では濃い灰色で囲われている。

1.2 完全 SLAM 問題

完全 SLAM 問題では、時刻 t における姿勢 x_t ではなく、全時刻における軌跡 $x_{1:t}$ に対して、事後確率が計算される。事後確率は $p(x_{1:t}, m|z_{1:t}, u_{1:t})$ のように表され、オンライン SLAM における事後確率 $p(x_t, m|z_{1:t}, u_{1:t})$ との関係は、以下のように周辺化として記述される。

$$p(x_t, m|z_{1:t}, u_{1:t}) = \int \int \cdots \int p(x_{1:t}, m|z_{1:t}, u_{1:t}) dx_1 dx_2 \cdots dx_{t-1} \quad (8)$$

完全 SLAM 問題は、Rao-Blackwellized パーティクルフィルタ (FastSLAM) や GraphSLAM を用いて解くことができる。前者は完全 SLAM 問題をオンラインで、後者はオフラインで解くアルゴリズムである。また前者はベイズフィルタ、後者は非線形最適化ベースの手法である。完全 SLAM 問題は、図 2 に示すような確率モデルとして表現される。変数間のグラフ構造は先程の図 1 と同一のものである。完全 SLAM において推定したいのは、ロボットの完全な軌跡 $x_{1:t}$ と地図 m であり、それらの変数が濃い灰色で囲われている。

1.3 SLAM 問題の難しさ

上記では地図 m の具体的な表現法については言及されなかった。地図の 1 つとして、レーザースキャナ (レーザレンジファインダ) から得られるスキャンデータ (点群) を貼り合わせて作られる、点群地図 (Point cloud map) が挙げられる。点群地図を用いるとき、スキャンデータ z_t を構成する各点が、地図上のどの点と対応するのか判定する必要がある。このようなスキャンデータと地図の対応関係を、変数 c_t として明示的に導入するのは有効である。対応付け変数 c_t を用いると、オンライン SLAM 問題における事後確率は $p(x_t, m, c_t|z_{1:t}, u_{1:t})$ 、完全 SLAM 問題の事後確率は $p(x_{1:t}, m, c_{1:t}|z_{1:t}, u_{1:t})$ のように表される [1][3][4]。

SLAM では、連続空間における姿勢 x_t や地図 m の推定 (非線形最適化やフィルタ処理) だけでなく、離散的な対応付け変数 c_t の推定、言い換えるとスキャンデータと地図の対応付け問題 (組み合わせ最適化問題) を解く必要がある。このように SLAM には連続的な問題と離散的な問題の双方が含まれている。連続的なパラメータ x_t, m 、離散的なパラメータ c_t の個数は、普通どちらも大きくなる。非線形最適化により x_t, m を求める場合、次元数が大きくなると局所解に陥りやすくなる。また取り得る全ての対応付け $c_{1:t}$ の場合の数は、時刻 t が大きくなるに従って指数的に増加する。これより解の候補は莫大になり、事後分布を厳密に求めることは不可能となる [1][3][4]。




図1 オンライン SLAM 問題の確率モデル




図2 完全 SLAM 問題の確率モデル

参考文献

- [1] Sebastian Thrun, Wolfram Burgard, and Dieter Fox. 確率ロボティクス プレミアムブックス版. 株式会社マイナビ出版, 2016. 上田 隆一 訳.
- [2] 原 祥亮, 坪内 孝司, and 大島 章. 確率的に蓄積したスキャン形状により過去を考慮した Rao-Blackwellized Particle Filter SLAM. 日本機械学会論文集, 82(834):15-00421, February 2016.
- [3] 友納 正裕. 移動ロボットの環境認識 一地図構築と自己位置推定. システム制御情報学会誌, 60(12):509-514, 2016.
- [4] 友納 正裕. SLAM入門 一ロボットの自己位置推定と地図構築の技術一. オーム社, 2018.